

RĪGAS TEHNISKĀ UNIVERSITĀTE

Datorzinātnes, informācijas tehnoloģijas un enerģētikas fakultāte

Atskaite par otro praktisko darbu

Studiju kurss “Mākslīgā intelekta pamati”

Komandas numurs: L4

Darba izpildītāji:

Patriks Kulinskis 241LDB009,

Iļja Karpovs 241LDB004

Aleksejs Heidemanis 241LDB034,

Roberts Alonderis 241LDB023

Mācībspēks: Alla Anohina-Naumeca

Saite uz projektu:


https://github.com/patriks/2_praktiskais_darbs_MIP

Saite uz datu kopu: [Wine Quality - UCI Machine Learning Repository](#)

Mākslīgā intelekta rīku izmantošanas paziņojums

1. [Google Gemini](https://gemini.google.com/share/e8598baf148d), 2026, Gemini 3 Flash, <https://gemini.google.com/share/e8598baf148d>, tika izmantots, lai noformētu izmantotās informācijas avotus (**34. lpp.**)

Orange rīka darbplūsma



1.1 att. Orange rīka darbplūsma

I daļa

Datu kopas apraksts

Datu kopas nosaukums:

Wine Quality

Datu kopas avots:

<https://archive.ics.uci.edu/dataset/186/wine+quality>

Datu kopas izveidotājs un/vai īpašnieks:

Paulo Cortez, António Cerdeira, Fernando Almeida, Telmo Matos, José Reis. [[avots](#)]

Datu kopas problēmsfēras apraksts:

Datu kopa satur fizikāli ķīmiskās īpašības par portugāļu "Vinho Verde" šķirnes baltajiem vīniem. Mērķis ir prognozēt vīna kvalitāti, pamatojoties uz objektīvi izmērāmiem laboratorijas testiem, kas vīna ražošanas nozarē var aizstāt dārgu un subjektīvu manuālu degustāciju. [[avots](#)]

Datu kopas licencēšanas nosacījumi:

Datu kopa ir publiski pieejama ar [Creative Commons Attribution 4.0 International \(CC BY 4.0\)](#) licenci. Izmantošanai ir nepieciešama atsauce uz oriģinālu. [[avots](#)]

Informācija par datu kopas savākšanas veidu vai procedūru:


Dati tika savākti no 2004. gada maija līdz 2007. gada februārim, izmantojot Portugāles oficiālās sertifikācijas iestādes (CVRVV) sistēmu iLab, kas automātiski reģistrēja vīna paraugu fizikāli ķīmiskos testus un sensorās novērtēšanas rezultātus. Katra parauga rezultāts ir balstīts uz sensoriem novērtējumiem (izmantojot aklo degustāciju) un tika izmantota mediāna no vismaz 3 vīna ekspertu veiktajiem novērtējumiem. Katrs eksperts novērtēja vīna kvalitāti no 0 (ļoti slikta) līdz 10 (ļoti izcila). [[avots](#)].

Datu kopas satura apraksts

Datu objektu skaits datu kopā:

Datu kopa satur 4898 datu objektus pirms filtrēšanas (dublēto ierakstu dzēšanas) un 3189 pēc filtrēšanas. Trūkstošo vērtību nav [[avots](#)].

Datu kopas pazīmju (atribūtu) atspoguļojums kopā ar to lomām Orange rīkā:



1.2 att. Datu kopas pazīmju atspoguļojums ar to lomām Orange rīkā.

Klašu skaits datu kopā:

Sākotnēji - 7 (skala no 3 - 9)

Klašu apraksts:

Daudzklašu klasifikācija tiek veikta, pamatojoties uz pazīmi *quality*, kura sākotnēji satur vērtības no 3 līdz 9, taču oriģinālās vērtības tika sagrupētas 3 klasēs - Low [3-4], Medium [5-6] un High [7-9]. Vērtējumi tika sagrupēti, lai samazinātu klašu skaitu un uzlabotu klasifikatoru veiktspēju.

Datu objektu skaits, kas pieder katrai klasei:

Klases iezīme	Datu objektu skaits
Low	163
Medium	2372
High	654

Pazīmju apraksts:

Pazīmes apzīmējums/nosaukums	Pazīmes skaidrojums	Vērtību tips	Vērtību diapazons
Fixed acidity	Fiksētais skābums (Vīnskābe)	Nepārtraukts skaitlisks	3,80 - 14,20
Volatile acidity	Gaistošais skāb. (Etiķskābe)	Nepārtraukts skaitlisks	0,08 - 1,10
Citric acid	Citronskābe	Nepārtraukts skaitlisks	0 - 1,66
Residual sugar	Atlikušais cukurs pēc rūgšanas	Nepārtraukts skaitlisks	0,7 - 65,8
Chlorides	Hlorīdu daudzums	Nepārtraukts skaitlisks	0,009 - 0,346
Free sulfur dioxide	Brīvais sēra dioksīds	Nepārtraukts skaitlisks	2 - 289
Total sulfur dioxide	Kop. sēra dioksīds	Nepārtraukts skaitlisks	9 - 440
Density	Blīvums	Nepārtraukts skaitlisks	0,987 - 1,039
pH	Skābuma skala	Nepārtraukts skaitlisks	2,72 - 3,82
Sulphates	Sulfātu daudzums	Nepārtraukts skaitlisks	0,22 - 1,08
Alcohol	Alkohola saturs %	Nepārtraukts skaitlisks	8 - 14,2
Quality	Kvalitāte (Mērķa mainīgais)	Kategorisks	Low/Medium/High

Datu faila struktūra:

Info

3199 instances (no missing data)

11 features

Target with 3 values

No meta attributes.

Variables

☒ Show variable labels (if present)

☐ Visualize numeric values

☒ Color by instance classes

Selection

Clear Selection

☒ Select full rows

	quality	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
1	Medium	6.20	0.320	0.16	7.00	0.045	30.0	136.0	0.9949	3.18	0.47	9.6
2	Medium	8.10	0.220	0.43	1.50	0.044	28.0	129.0	0.9938	3.22	0.45	11
3	Medium	8.10	0.270	0.41	1.45	0.033	11.0	63.0	0.9908	2.99	0.56	12
4	Medium	6.60	0.230	0.40	4.20	0.035	17.0	109.0	0.9947	3.14	0.53	9.7
5	Medium	7.90	0.180	0.37	1.20	0.040	16.0	75.0	0.992	3.18	0.63	10.8
6	High	6.60	0.160	0.40	1.50	0.044	48.0	143.0	0.9912	3.54	0.52	12.4
7	Medium	8.30	0.420	0.62	19.25	0.040	41.0	172.0	1.0002	2.98	0.67	9.7
8	High	6.60	0.170	0.38	1.50	0.032	28.0	112.0	0.9914	3.25	0.55	11.4
9	Medium	6.30	0.480	0.04	1.10	0.046	30.0	99.0	0.9928	3.24	0.36	9.6
10	Medium	7.40	0.340	0.42	1.10	0.033	17.0	171.0	0.9917	3.12	0.53	11.3
11	Medium	6.50	0.310	0.14	7.50	0.044	34.0	133.0	0.9955	3.22	0.50	9.5
12	High	6.40	0.310	0.38	2.90	0.038	19.0	102.0	0.9912	3.17	0.35	11
13	High	6.80	0.290	0.42	1.70	0.049	41.0	122.0	0.993	3.47	0.48	10.5
14	Medium	7.60	0.670	0.14	1.50	0.074	25.0	168.0	0.9937	3.05	0.51	9.3
15	Medium	6.60	0.270	0.41	1.30	0.052	16.0	142.0	0.9951	3.42	0.47	10
16	Medium	7.00	0.250	0.32	9.00	0.046	56.0	245.0	0.9955	3.25	0.50	10.4
17	Medium	6.90	0.240	0.35	1.00	0.052	35.0	146.0	0.993	3.45	0.44	10
18	Medium	7.00	0.280	0.39	8.70	0.051	32.0	141.0	0.9961	3.38	0.53	10.5
19	Medium	7.40	0.270	0.48	1.10	0.047	17.0	132.0	0.9914	3.19	0.49	11.6
20	High	7.20	0.320	0.36	2.00	0.033	37.0	114.0	0.9906	3.10	0.71	12.3
21	Medium	8.50	0.240	0.39	10.40	0.044	20.0	142.0	0.9974	3.20	0.53	10
22	Medium	6.30	0.140	0.34	1.10	0.042	7.0	47.0	0.9934	3.47	0.40	10.2
23	Medium	7.40	0.250	0.36	2.05	0.050	31.0	100.0	0.992	3.19	0.44	10.8
24	Medium	6.20	0.120	0.34	1.50	0.045	43.0	117.0	0.9939	3.42	0.51	9
25	Medium	5.80	0.270	0.20	14.95	0.044	22.0	179.0	0.9962	3.37	0.37	10.2
26	Medium	7.30	0.280	0.43	1.70	0.080	21.0	123.0	0.9905	3.19	0.42	12.8
27	Medium	6.50	0.390	0.23	5.40	0.051	25.0	149.0	0.9934	3.24	0.35	10
28	Medium	7.00	0.330	0.32	1.20	0.053	38.0	138.0	0.9906	3.13	0.28	11.2
29	Medium	6.70	0.230	0.39	2.50	0.172	63.0	158.0	0.9937	3.11	0.36	9.4
30	Medium	6.70	0.240	0.39	2.90	0.173	63.0	157.0	0.9937	3.10	0.34	9.4
31	Medium	6.60	0.240	0.27	1.40	0.057	33.0	152.0	0.9934	3.22	0.56	9.5
32	Medium	6.70	0.230	0.26	1.40	0.060	33.0	154.0	0.9934	3.24	0.56	9.5
33	High	7.40	0.180	0.31	1.40	0.058	38.0	167.0	0.9931	3.16	0.53	10
34	Low	6.20	0.450	0.26	4.40	0.063	63.0	206.0	0.994	3.27	0.52	9.8

1.3 att. Datu faila struktūras attēlojums.

Informācija par trūkstošajām pazīmju vērtībām:


Datu kopā trūkstošo vērtību nav.

Informācija par izlecošajām pazīmju vērtībām:

Ar Box Plot logrīku tika konstatēts, ka vairākām pazīmēm pastāv atsevišķas izlecošās vērtības. Īpaši izteiktas tās novērojamas pazīmēs *residual sugar* un *free sulfur dioxide*, kur atsevišķas vērtības ievērojami pārsniedz vidējās vērtības. Piem., pazīmei *residual sugar* lielākā daļa vērtību koncentrējas ap ~5.5, taču novērojams viens datu punkts ar vērtību ap 65.8, kas norāda uz izteiktu novirzi no pārējās datu kopas, taču pēc savstarpējās apspriedes nolēmām tās paturēt, jo tās nav kļūdas, bet fizikāli ķīmiskās īpatnības katram vīnam.

Informācija par dublētiem datu objektiem:

Datu kopā tika konstatēti 1709 dublēti datu objekti. Dublētie ieraksti tika noņemti, izmantojot Unique logrīku ar iestatījumu Discard non-unique instances. Rezultātā datu kopa samazinājās no 4898 uz 3189 datu objektiem.




1.4 att. Unique logrīka izmantošana dublēto datu objektu noņemšanai.

Informācija par korelējošām pazīmju vērtībām:

Datu kopā tika konstatētas stipras korelācijas starp dažādām pazīmēm. Piem., blīvums un atlikušais cukurs ($r=0,801$), blīvums un alkohols ($r= -0,74$) un brīvais un kopīgs sēra dioksīds ($r=0,62$). Tika pieņemts lēmums tos saglabāt, jo turpmāk izmantotie algoritmi spēj tos izturēt - bet korelāciju būtu jāņem verā rezultātu apstrādē.


Informācija par vērtību normalizēšanas nepieciešamību:

Normalizācija bija nepieciešama, jo dažas vērtības stipri atšķiras - piemēram kopīgais sēra dioksīds (440 maksimums) un hlorīds (maksimums ir 0,35). Bez normalizācijas nebūtu iespējams korekti izmantot attāluma metrikas. Tika izmantota standartizācija (vidēja vērtība = 0 ; standartnovirze = 1), izmantojot *Preprocess* logrīku. Tieši standartizācija tika izvēlēta nevis min-max normalizācija, jo datu kopā ir izlecošās vērtības - min-max metode ir jutīga pret tām, jo ekstrēmas vērtības sabojā visu skalu.




1.5 att. Vērtību normalizēšana, izmantojot Preprocess logrīku Orange vidē.


Datu kopas vizuālais un statistiskais atspoguļojums




1.6 att. Divdimensionāla izkliedes diagramma, kas ilustrē klašu atdalāmību pēc pazīmēm *density* un *alcohol*.




1.7 att. Divdimensionāla izkliedes diagramma, kas ilustrē klašu atdalāmību pēc pazīmēm *citric acid* un *volatile acidity*.




1.8 att. Histogramma, kas parāda klašu sadalījumu pēc pazīmes *alcohol*.




1.9 att. Histogramma, kas parāda klašu sadalījumu pēc pazīmes *volatile acidity*.



1.10 att. Pazīmes *alcohol* vērtību sadalījums datu kopā.



1.11 att. Pazīmes *residual sugar* vērtību sadalījums datu kopā.



1.12 att. Datu kopas statistisko rādītāju attēlojums.

Atbildes uz jautājumiem

Vai klases datu kopā ir līdzsvarotas, vai dominē viena klase (vai vairākas klases)?

Datu kopā klases nav līdzsvarotas. Dominē klase Medium ar 2372 objektiem, kamēr Low satur tikai 163 objektus un High - 654 objektus.

Vai datu vizuālais atspoguļojums ļauj redzēt datu struktūru?

Ierobežotā veidā ir iespēja redzēt struktūru vizuāli un izdarīt secinājumus - kā redzams 1.6. att., High klasei ir raksturīgs augstāks alkohola saturs un zemāks blīvums salīdzinājumā ar pārējām klasēm, taču atspoguļojums nav perfekts, jo datu punkti ievērojami pārklājas, īpaši Medium un Low klasēm.

Cik datu grupējumus ir iespējams identificēt, pētot datu vizuālo atspoguļojumu?

Pētot izkliedes diagrammas (skat. 1.6. att., 1.7. att.), nevar īsti skaidri identificēt 3 atsevišķus grupējumus, jo datu punkti diezgan pārklājas. Vienīgais daļēji atdalāmais grupējums ir High klase, kurai raksturīgs augstāks alkohola saturs un zemāks blīvums. Medium un Low klases vizuāli var redzēt, ka saplūst kopā.

Vai identificētie datu grupējumi atrodas tuvu viens otram vai tālu viens no otra?

Grupējumi ir diezgan tuvu viens otram ar pārklāšanos, īpaši Medium un Low gadījumā, jo abiem ir raksturīgs zems alkohola saturs, kā arī augsts cukurs.

Secinājumi, kas izriet no statistisko rādītāju analīzes

Vislielāka variācija starp klasēm ir alcohol pazīmei (skat. 1.8. att.) - High klases vīnam ir ievērojami augsts alkohola koeficients (no 8,5 līdz 14,2) salīdzinājuma ar Low klasi (no 8 līdz 13,5). Volatile acidity, savukārt, rāda pretējo tendenci - jo augstāka kvalitāte, jo zemākas vērtības - tātad High klase tā ir robežas no 0,1 līdz 0,76, bet Low tā ir no 0.11 līdz 1.10, kas norāda uz šo pazīmju potenciālo nozīmīgumu klasifikācijā.

Secinājumi par atlasītajām pazīmēm

Tālākajā analīzē tiks izmantotas visas 11 pazīmes, jo algoritmi paši spēj noteikt to nozīmīgumu. Balstoties uz vizuālo analīzi, paredzam, ka, visticimāk, tiks izcelti: alcohol, volatile acidity, density un chlorides. Mērķa mainīgais joprojām ir *quality*.


II daļa

Hierarhiskā klasterēšana

Orange rīkā pieejamo hiperparametru apraksts:

Hiperparametrs	Apraksts
Zoom	Ļauj pietuvināt vai attālināt dendrogrammu, lai labāk redzētu struktūru.
Linkage	Iespēja mainīt starpklasteru attālumu. Piem - Single aprēķina attālumu starp abu klasteru tuvākajiem elementiem. Ward - minimizē dispersiju, apvienojot klasterus ar mazāko pieaugumu
Annotations	Dendrogrammā esošo mezglu (node) etiķetes
Pruning	Dendrogrammas maksimālais dziļums. None - pilns koks.
Selection	Nosaka, kā tiek izvēlēti klasteri: manuāli klikšķinot dendrogrammā, izmantojot augstuma robežlīniju (Height ratio), vai norādot klasteru skaitu (Top N).
Metric (<u>Caur Distance widget</u>)	Iespēja mainīt attāluma metriku - Eiklīda, Manhettena, Pirsona utt.

[avots]




2.1 att. Hierarhiskās klasterēšanas logrīka iestatījumi Orange rīkā.

Eksperimentu apraksts

1. eksperiments - augsts līmenis


Horizontālā atdalošā līnija novietota pie augstas vērtības (85%), tika iegūti 2 klasteri - C1 (2432 objekti) un C2 (757 objekti). Šāds sadalījums nav pietiekams, jo zināmais klašu skaits ir 3, tātad algoritms nespēj atdalīt visas klases.



2.2 att. Dendrogramma pēc 1. eksperimenta ar hierarhisko klasterēšanu.

2. eksperiments - vidējs līmenis


Horizontālā atdalošā līnija novietota pie 60%, tika iegūti 3 klasteri - C1 (2432), C2 (79), C3 (678). Klasteru skaits atbilst zināmajam klašu skaitam (3) un klasteru izmēri aptuveni atspoguļo zināmo klašu sadalījumu.



2.3 att. Dendrogramma pēc 2. eksperimenta ar hierarhisko klasterēšanu.

3. eksperiments - zems līmenis

Horizontālā atdalošā līnija novietota pie 40% un tika iegūti 7 klasteri C1 (627), C2 (205), C3 (670), C4 (513), C5 (417), C6 (79), C7 (678). Klasteru 2.3x skaits pārsniedz zināmo klašu skaitu, taču izmēri ir salīdzinoši vienmērīgāki nekā iepriekšējos eksperimentos, kas norāda, ka zemāks atdalīšanas līmenis ļauj algoritmam sīkāk sadalīt datu struktūru. Tiesa gan tas vairs neatbilst zināmajam klašu skaitam.



2.4 att. Dendrogramma pēc 3. eksperimenta ar hierarhisko klasterēšanu.

Secinājumi no eksperimentiem:


Analizējot dendrogrammu dažādos līmeņos, var secināt, ka klasteru skaits ir atkarīgs no atdalošās līnijas novietojuma. Vislabākais rezultāts tika iegūts 2. eksperimentā (60%), kur iegūtie 3 klasteri pēc izmēra aptuveni atbilst zināmajam klašu sadalījumam (Medium, High, Low), kas liecina par daļēju atpazīšanu.

K-vidējo algoritms

Orange rīkā pieejamo hiperparametru apraksts:

Hiperparametrs	Apraksts
Number of Clusters	Norāda, cik klasterus algoritms izveidos. Var izvēlēties fiksētu skaitu vai diapazonu (no X līdz Y), lai redzētu Silueta rezultātus.
Preprocossing	Ja izvēlēts "Normalize columns", dati tiek normalizēti (vidējā vērtība 0, standarta novirze 1).
Initialization	Veids, kā algoritms sāk klasterizāciju: "KMeans++" izvēlas pirmo centru nejauši, nākamie tiek izvēlēti no atlikušajiem punktiem ar varbūtību proporcionālu attāluma kvadrātam no tuvākā centra. "Random initialization" sāk ar nejaušu klasteru piešķiršanu, ko vēlāk uzlabo ar iterācijām.
Re-runs	Cik reižu algoritms tiek palaists no nejaušām sākuma pozīcijām. Tiks izmantots rezultāts ar zemāko kvadrātu summu klastera ietvaros.
Maximum Iterations	Max iterāciju skaits katrā algoritma izpildes reizē, var iestatīt manuāli.

[avots]




2.5 att. K-vidējo algoritma logrīka iestatījumi Orange rīkā.

Eksperimentu apraksts

K-vidējo algoritmam aprēķinājām Silueta koeficientu, lai pārbaudītu dažādas k vērtības un analizētu, kā dati sadalās klasteros. Iestatījumi tika mainīti, kā redzams attēlā:


- Klasteru skaits - 2-6;
- Normalizācija iespējota, lai uzlabotu datu apstrādi (dati tika standartizēti);
- Sākotnējā centru ģenerēšana - KMeans++ ar max iterāciju skaitu 200.



2.6 att. Silueta koeficientu vērtības.

Labākais Silueta koeficients (**0.214**) tika iegūts pie $k = 2$, tomēr atdalījums nav izteikti labs, jo koeficienta vērtība ir salīdzinoši zema.

Izkliedes diagramma parāda, ka izveidojas divi klasteri (C1 (1108 objekti) un C2 (2081 objekti)). Objekti daļēji atdalās, taču ir novērojama arī pārklāšanās.



2.7 att. Izkliedes diagramma, kas ilustrē sadalījumu klasteros C1 un C2.

Secinājumi no eksperimentiem:

Silueta koeficients rāda, ka labākais rezultāts ir pie $k=2$ (0.214), taču klasteru atdalāmība nav izteikta. Apskatot izkliedes diagrammu (skat. 2.7. att.) ar pazīmēm *density* un *free sulfur dioxide*, redzams, ka abi klasteri (C1 un C2) pārklājas un nav pavisam skaidri nodalīti, tātad pazīmes nepietiekami labi atšķir datus, un K-vidējo algoritms nespēj izveidot skaidras robežas starp klasteriem.

Noslēguma secinājumi

Pamatojoties uz abu algoritmu rezultātiem, var secināt, ka datu kopas klases (Low, Medium, High) nav labi atdalāmas. K-vidējo algoritms pie $k=2$ sasniedza Silueta koeficientu tikai 0.214, un izkliedes diagrammā klasteri pārklājas - palielinot k , rezultāti tikai pasliktinās. Hierarhiskā klasterēšana, bīdīt horizontālo atdalošo līniju, palielina klasteru skaitu, taču klašu atdalāmību tas neuzlabo - labākais rezultāts tika iegūts pie 60%, kur 3 klasteru izmēri aptuveni atbilda zināmajam klašu sadalījumam.

III daļa

Izvēlēto algoritmu apraksts

Pirmā algoritma nosaukums:

Random forest (Gadījuma mežs)

Pirmā algoritma apraksts:

Algoritms, kas apvieno vairākus lēmumu kokus, kur katrs ir apmacīts ar nejaušo datu apakškopu. Algoritms tika izvēlēts, jo ir īpaši izturīgs pret data kopas problēmām - korelējošām pazīmēm un izlecošajām vērtībām.

[\[avots\]](#)

Otrā algoritma nosaukums:

kNN (K tuvāko kaimiņu algoritms)

Otrā algoritma apraksts:

Klasificē datus, apskatot k tuvākos apmācības piemērus, piešķirot klasi. Ir izvēlēts kā vieglāka alternatīva Random Forest, bet arī spēj demonstrēt datu klases atdalāmību.

[\[avots\]](#)


Hiperparametru apraksts

Hiperparameters	Apraksts un vērtības
Mākslīgo neironu tīkli	
Neurons in hidden layers	Neironu skaits katrā slānī. Piem. 100 = viens slānis ar 100 neironiem
Activation	Aktivizācijas funkcija. Piem., ReLU, Tanh, Logistic, Identity.
Solver	Optimizācijas algoritms. Piem., Adams (ātrs), SGD (Stohastiskais gradients), L-BFGS-B (Mazām kopām)
Regularization	Alpha koeficients. Lielāka vērtība = vienkāršāks modelis, mazāks risks.
Maximal number of iterations	Iterāciju skaits.
Random forest	
Number of trees	Koku skaits mežā - vairāk koku = stabilāks modelis, bet lēnāks.
Number of attributes	Pazīmju skaits apskatīšanai
Depth limit	Maksimālais dziļums - ierobežo pārmācīšanu.
kNN	
Number of neighbors	Kaimiņu skaits klašu izvēlei. Mazs k = jutīgs pret troksni, liels k = gludāka robeža.
Metric	Attāluma metrika - Euclidean, Manhattan, Chebyshev, Mahalanobis

Weight	Izvēles metode. Uniform - visiem vienāda nozīme, distance - tuvākie ir svarīgāki.
--------	---

[[Neural](#)]; [[Random Forest](#)]; [[kNN](#)]

Informācija par testa un apmācības datu kopām



3.1 att. Datu kopas sadalīšana apmācības un testa kopās.

Datu objektu skaits apmācības datu kopā:

2552 objekti apmācībai

Datu objektu % proporcija apmācības datu kopā:

Klases iezīme	Datu objektu skaits apmācības datu kopā	Datu objektu % proporcija apmācības datu kopā
Low	131	5,13%
Medium	1898	74,37%
High	523	20,50%

Datu objektu skaits testa datu kopā:


637

Datu objektu % proporcija testa datu kopā:


Klases iezīme	Datu objektu skaits testa datu kopā	Datu objektu % proporcija testa datu kopā
Low	32	5,02%
Medium	474	74,41%
High	131	20,57%

Eksperimenti ar mākslīgo neironu tīklu


Eksperiments	Hiperparametru vērtības
1.eksperiments	(100 neurons),(ReLu activation),(Adam solver),(alpha = 0,001)(1000 iterations)
2.eksperiments	(100,50 neurons),(ReLu activation),(SGD solver),(alpha = 1)
3.eksperiments	(200,100 neurons),(tanh activation),(SGD solver),(alpha = 50)




3.2 att. 1. eksperimenta hiperparametru vērtības mākslīgajam neironu tīklam.




3.3 att. 1. eksperimenta veikspējas metrikas mākslīgajam neironu tīklam.



3.4 att. 2. eksperimenta hiperparametru vērtības mākslīgajam neironu tīklam.



3.5 att. 2. eksperimenta veikspējas metrikas mākslīgajam neironu tīklam.



3.6 att. 3. eksperimenta hiperparametru vērtības mākslīgajam neironu tīklam.

Model	AUC	CA	F1	Prec	Recall	MCC
Neural test	0.745	0.744	0.635	0.554	0.744	0.000

3.7 att. 3. eksperimenta veikspējas metrikas mākslīgajam neironu tīklam.

Secinājumi no eksperimentiem:

Vislabākais eksperiments pēc veikspējas ir 2. (skat. 3.5. att.), sasniedzot CA = 0,801, F1 = 0,774 un 0,781 precizitāti. Alpha koeficients šī eksperimentā spēj vislabāk pielāgoties datiem. Liekot parāk mazas un parāk lielas vērtības veido mazāk balansētu modeli ar vajākiem rezultātiem.

Testēšanai izvēlētais modelis:

Ir nolemts izmantot 2. eksperimenta modeli - divi neironu slāņi (100,50), alpha = 1 un SGD solvers, lielākas precizitātes dēļ.

Eksperimenti ar Random forest

Eksperiments	Hiperparametru vērtības
1.eksperiments	(10 trees),(Depth unlimited),(Min.Split 2)
2.eksperiments	(50 trees),(Depth 10),(Min.Split 5)
3.eksperiments	(100 trees),(Depth 20),(Min.Split 2)

3.8 att. 1. eksperimenta hiperparametru vērtības Random Forest algoritmam.

Test and Score - Orange

☐ Cross validation

Number of folds: 10

☒ Stratified

☐ Cross validation by feature

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Neural test	0.847	0.801	0.774	0.781	0.801	0.425
Random Forest	0.816	0.780	0.758	0.758	0.780	0.374

3.9 att. 1. eksperimenta veikspējas metrikas Random Forest algoritmam.

Random Forest - Orange

Name: Random Forest

Basic Properties

Number of trees: 50

☐ Number of attributes considered at each split: 5

☐ Replicable training

☐ Balance class distribution

Growth Control

☒ Limit depth of individual trees: 10

☒ Do not split subsets smaller than: 5

☐ Apply

3.10 att. 2. eksperimenta hiperparametru vērtības Random Forest algoritmam.

Test and Score - Orange

☐ Cross validation

Number of folds: 10


☒ Stratified

☐ Cross validation by feature


Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Neural test	0.847	0.801	0.774	0.781	0.801	0.425
Random Forest	0.846	0.793	0.761	0.771	0.793	0.392

3.11 att. 2. eksperimenta veikspējas metrikas Random Forest algoritmam.



3.12 att. 3. eksperimenta hiperparametru vērtības Random Forest algoritmam.



3.13 att. 3. eksperimenta veikspējas metrikas Random Forest algoritmam.

Secinājumi no eksperimentiem:


Palielinot koku skaitu, modelis kļuva stabilāks - precizitāte mainās no 0,758 (skat. 3.9. att.) līdz 0,792 (skat. 3.13. att.). Dziļuma ierobežošana tomēr mazinā veiktspēju - tas liecina par to, ka šādi kopai nepieciešams dziļāks koks.

Testēšanai izvēlētais modelis:

Tika nolemts izmantot 3. eksperimenta modeli - 100 koki, dziļums 20 un sadalīšana tikai no 2, labākas precizitātes dēļ, sasniedzot precizitātes vērtību 0,792 , ka arī AUC = 0,850.

Eksperimenti ar kNN

Eksperiments	Hiperparametru vērtības
1.eksperiments	(5 neighbours), (Euclidean metric), (Uniform weight)
2.eksperiments	(15 neighbours), (Euclidean metric), (Distance weight)
3.eksperiments	(30 neighbours), (Manhattan metric), (Uniform weight)




3.14 att. 1. eksperimenta hiperparametru vērtības kNN algoritmam.

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Neural test	0.847	0.801	0.774	0.781	0.801	0.425
Random Forest	0.850	0.808	0.785	0.792	0.808	0.454
kNN	0.768	0.786	0.764	0.764	0.786	0.394

3.15 att. 1. eksperimenta veikspējas metrikas kNN algoritmam.




3.16 att. 2. eksperimenta hiperparametru vērtības kNN algoritmam.

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Neural test	0.847	0.801	0.774	0.781	0.801	0.425
Random Forest	0.850	0.808	0.785	0.792	0.808	0.454
kNN	0.807	0.805	0.776	0.792	0.805	0.439

3.17 att. 2. eksperimenta veikspējas metrikas kNN algoritmam.



3.18 att. 3. eksperimenta hiperparametru vērtības kNN algoritmam.

Evaluation results for target (None, show average over classes)							
Model	AUC	CA	F1	Prec	Recall	MCC	
Neural test	0.847	0.801	0.774	0.781	0.801	0.425	
Random Forest	0.850	0.808	0.785	0.792	0.808	0.454	
kNN	0.815	0.797	0.755	0.755	0.797	0.398	

3.19 att. 3. eksperimenta veikspējas metrikas kNN algoritmam.

Secinājumi no eksperimentiem:

Palielinot k vērtību, modelis kļuva stabilāks. *Weight: By Distances* arī uzradīja uzlabojumu salīdzinot ar *Weight: Uniform* - tas nozīmē, ka tuvākie kaimiņi ir informatīvāki. Precizitātes vērtības pieauga no 0,764 (skat. 3.15. att.) līdz 0,792 (skat. 3.17. att.), ka arī AUC no 0,768 (skat. 3.15. att.) līdz 0,815 (skat. 3.19. att.).

Testēšanai izvēlētais modelis:

Izvēlēts 2. eksperimenta modelis - 15 kaimiņi, Eiklīda attāluma metrika un svara sadalīšana pēc distances - lielākas precizitātes dēļ, sasniedzot precizitāti 0,792.

Apmācīto modeļu testēšanas rezultāti

Test and Score - Orange

File Edit View Window Help

☐ Cross validation
Number of folds: 10
☒ Stratified

☐ Cross validation by feature

☐ Random sampling
Repeat train/test: 10
Training set size: 66 %
☒ Stratified

☐ Leave one out

☐ Test on train data

☒ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Neural test	0.847	0.801	0.774	0.781	0.801	0.425
Random Forest	0.850	0.808	0.785	0.792	0.808	0.454
kNN	0.807	0.805	0.776	0.792	0.805	0.439

Compare models by: Area under ROC curve ☐ Negligible diff.: 0.1

	Neural test	Random Forest	kNN
Neural test			
Random Forest			
kNN			


Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

2552 | 637 | 637 | 3×637

3.20 att. Apmācīto modeļu testēšanas rezultāti.


ROC analīze

Low:




3.21 att. ROC l kne klasei *Low*.

Medium:




3.22 att. ROC līkne klasei *Medium*.

High:




Confusion Matrix

Neural test:




3.24 att. *Confusion* matrica mākslīgajam neironu tīklam.

Random forest:



3.25 att. *Confusion* matrica Random Forest algoritmam.

kNN:



3.26 att. Confusion matrica kNN algoritmam.

Secinājumi pēc testēšanas:

Random forest algoritms uzrādīja vislabāko veikspēju visās metrikas, iegūstot vislielākas vērtības gan AUC (0,850), gan F1 (0,785), gan precizitāte (0,792) (skat. 3.20. att.).

Neironu tīkls ir otrs labākais pēc precizitātes, iegūstot līdzīgas vērtības - AUC (0,847), F1 (0,774), Precizitāte (0,781) (skat. 3.20. att.).

Vissliktāk ar šo datu kopu strādāja kNN algoritms, iegūstot visszemākās vērtības - AUC (0,807), F1 (0,776), lai gan atsevišķos gadījumos tas uzrādīja salīdzinoši lielu precizitāti (0,792) (skat. 3.20. att.).

Svarīgi arī pieminēt, ka vienā no eksperimentiem ar kNN algoritms parādīja interesantu rezultātu - MCC = 0. Tas norāda uz to, ka modelis galvenokārt prognozē vienu no trīs klasēm, ignorējot pārējās. Tas liecina par to, ka klases tiešām nav līdzsvarotas, kas jau tika secināts pirmajā darba daļā.

Kopumā, šo trīs modeļu veikspēja bija aptuveni 80% CA, kas atbilst datiem no otrās darba daļas - objekti šajā datu kopā pārklājas un pilnīgi tos nošķirt bez papildu līdzvarošanas nav gluži iespējams.

Izmantotie informācijas avoti

1. Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). *Wine Quality*. UCI Machine Learning Repository. <https://doi.org/10.24432/C56S3T>
2. Creative Commons. (n.d.). *Attribution 4.0 International (CC BY 4.0)*. <https://creativecommons.org/licenses/by/4.0/legalcode>
3. Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). *Modeling wine preferences by data mining from physicochemical properties*. In *Decision Support Systems*, 47(4), 547-553. Elsevier. <https://repositorium.uminho.pt/server/api/core/bitstreams/f3dd2aa2-9eda-4eba-b50e-6306a0bd0c66/content>
4. Orange Data Mining. (n.d.). *Hierarchical Clustering*. Orange Widget Catalog. <https://orangedatamining.com/widget-catalog/unsupervised/hierarchicalclustering/>
5. Orange Data Mining. (n.d.). *K-Means*. Orange Widget Catalog. <https://orangedatamining.com/widget-catalog/unsupervised/kmeans/>
6. GeeksforGeeks. (2026. gada 2. maijs). *Random Forest algorithm in machine learning*. <https://www.geeksforgeeks.org/machine-learning/random-forest-algorithm-in-machine-learning/>
7. GeeksforGeeks. (2026. gada 2. maijs). *K-Nearest Neighbors(KNN) algorithm*. <https://www.geeksforgeeks.org/machine-learning/k-nearest-neighbours/>
8. Orange Data Mining. (n.d.). *Neural Network*. Orange Widget Catalog. <https://orangedatamining.com/widget-catalog/model/neuralnetwork/>
9. Orange Data Mining. (n.d.). *Random Forest*. Orange Widget Catalog. <https://orangedatamining.com/widget-catalog/model/randomforest/>
10. Orange Data Mining. (n.d.). *k-Nearest Neighbors*. Orange Widget Catalog. <https://orangedatamining.com/widget-catalog/model/knn/>
11. Orange Data Mining. (n.d.). *Orange documentation*. <https://orangedatamining.com/docs/>

Pielikums

1. <https://gemini.google.com/share/e8598baf148d>